UNIVERSIDADE DO VALE DO ITAJAÍ

Curso de Ciência da Computação — Disciplina de Processamento de Imagens

PROJETO M2.2

SEGMENTAÇÃO E MORFOLOGIA MATEMÁTICA

RELATÓRIO TÉCNICO

Acadêmicos: Aquilis Visintainer, Filipe Dietrich e Nilton Alves

Professor: Felipe Viel

Disciplina: Processamento de Imagens

Itajaí — SC, 2026

1. PROJETO 1 — SEGMENTAÇÃO POR K-MEANS

1.1 Seleção das imagens e do parâmetro K

Para 2apples.jpg, escolheu-se K = 3 a fim de representar as três regiões cromáticas predominantes: tonalidades verdes, vermelhas e fundo claro. Na imagem 2or4objects.jpg, escolheu-se K = 5 devido à maior diversidade de tonalidades provocada por detalhes em forma de coração, reflexos, sombras e fundo. O parâmetro K indica a quantidade de agrupamentos, não uma correspondência obrigatória com o número de objetos.

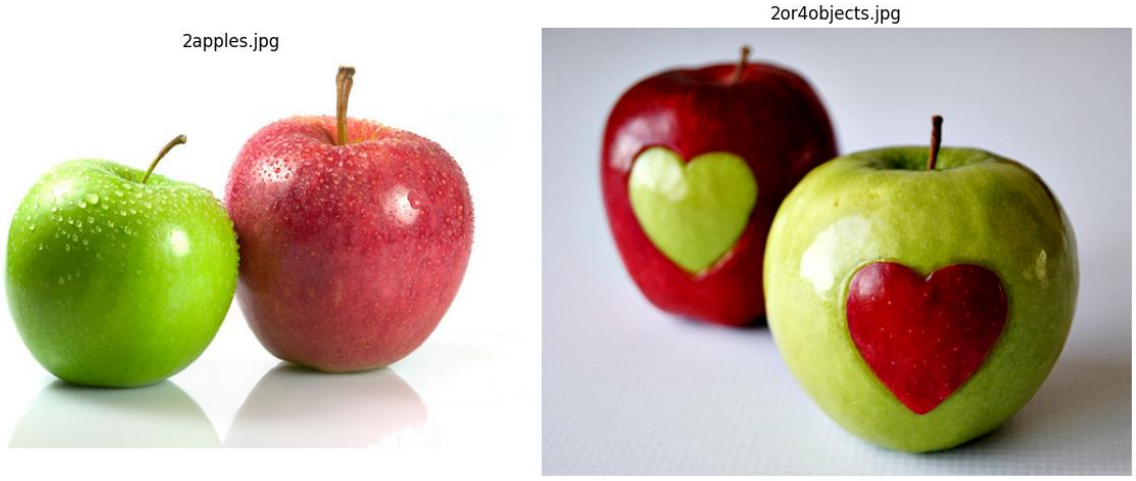


Figura 1 — imagens originais 2apples.jpg e 2or4objects.jpg lado a lado. Origem: carregamento do Projeto 1.

1.2 Implementação do K-means RGB (3D)

Cada pixel foi representado pelos três canais RGB. O algoritmo sorteou K pixels como centroides iniciais, atribuiu cada pixel ao centroide de menor distância euclidiana ao quadrado e atualizou os centroides pela média dos valores do grupo. As etapas foram repetidas até deslocamento total menor que 0,1 ou limite de 100 iterações. A semente aleatória fixa 42 tornou a inicialização reproduzível.

Trecho principal da função executar_kmeans():

```
distancias = np.sum(
    (dados[:, None, :] - centroides[None, :, :]) ** 2,
    axis=2
)
rotulos = np.argmin(distancias, axis=1)
for grupo in range(k):
    pixels_grupo = dados[rotulos == grupo]
    if len(pixels_grupo) > 0:
        novos_centroides[grupo] = pixels_grupo.mean(axis=0)
```

1.3 Resultados e discussão do RGB

Imagem	K	Convergência	Análise
2apples.jpg	3	68 iterações	Boa distinção cromática geral; brilhos e reflexos confundidos com o fundo.
2or4objects.jpg	5	31 iterações	Maçãs e corações fragmentados em grupos devido às variações de cor e sombra.

O algoritmo agrupou pixels segundo suas cores, mas regiões distintas com tonalidades semelhantes compartilharam clusters. Em contrapartida, o brilho em uma mesma maçã podia ser associado ao fundo. A separação de agrupamentos de cor não equivale, portanto, à identificação completa de objetos.

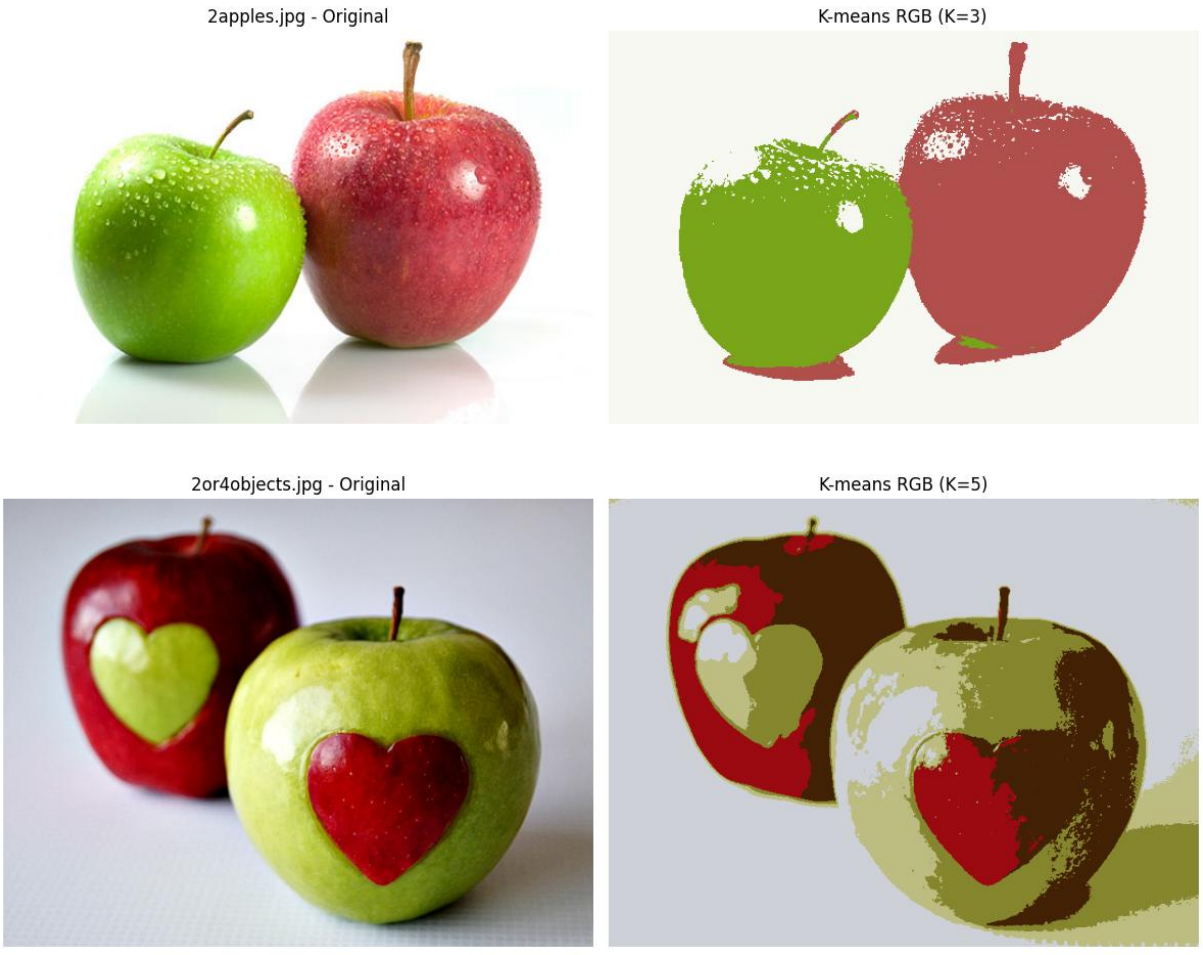


Figura 2 — K-means RGB: originais e segmentadas das duas imagens de maçãs. Origem: aplicação do K-means RGB.

1.4 Visualização dos clusters no espaço RGB

O gráfico de dispersão 3D foi produzido para 2or4objects.jpg, com eixos R, G e B e marcadores X nos cinco centroides. Para legibilidade, foram exibidos 10.000 dos 371.700 pixels, escolhidos aleatoriamente. A segmentação foi realizada sobre todos os pixels da imagem; a amostragem afetou somente o gráfico.

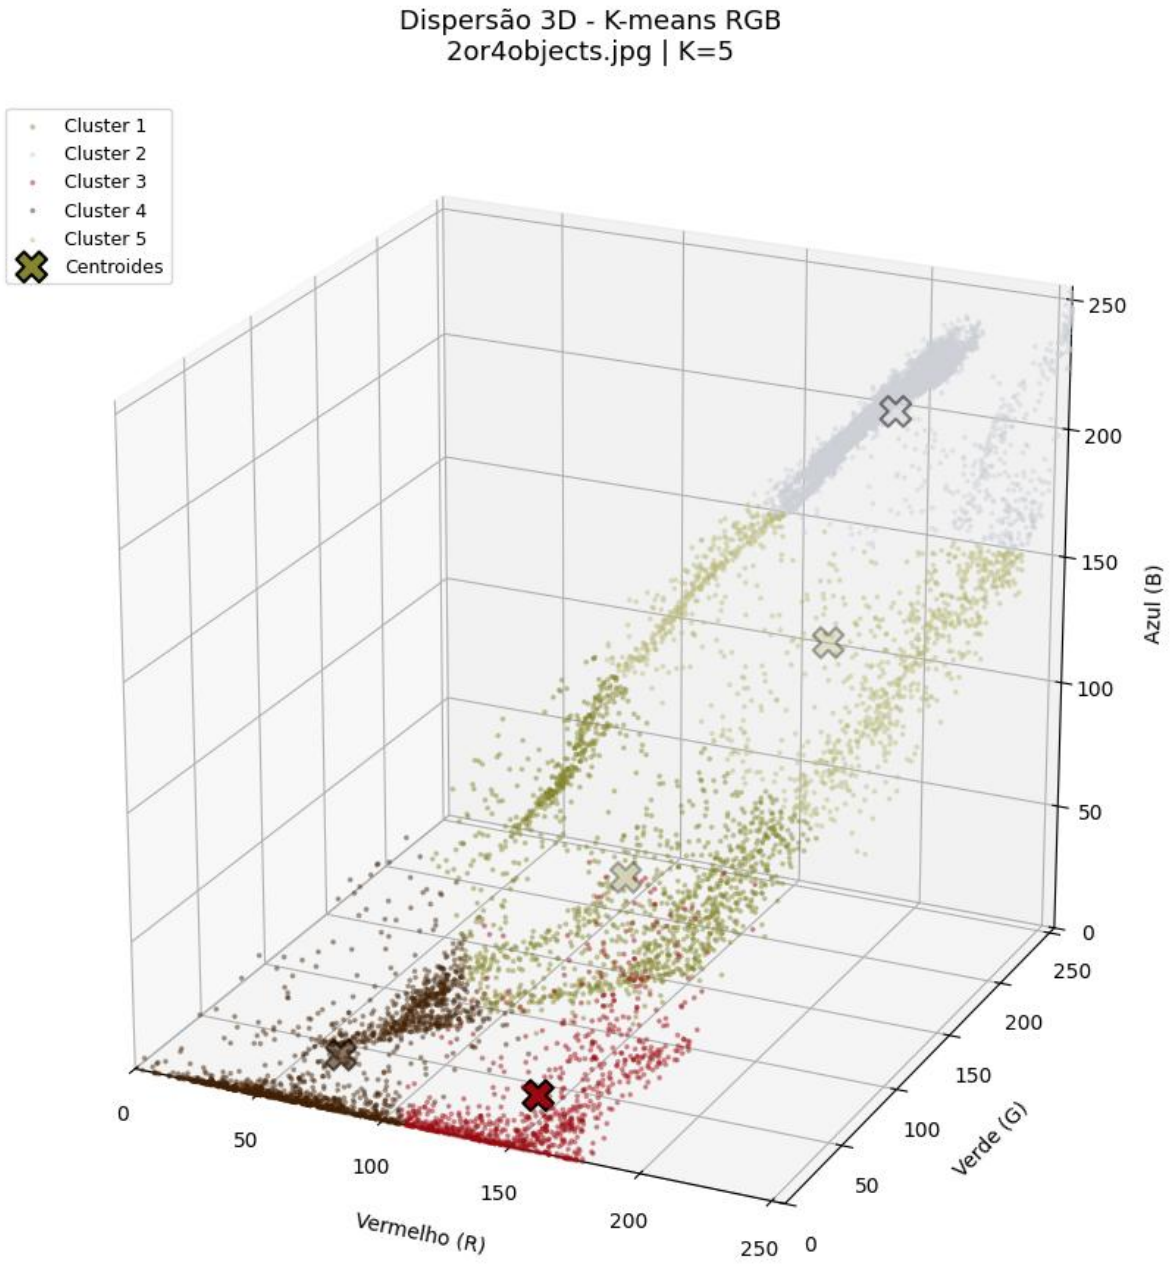


Figura 3 — gráfico de dispersão RGB 3D da imagem 2or4objects.jpg, com centroides. Origem: plotar_kmeans_rgb_3d.

O gráfico destacou concentrações de tonalidades e regiões de aproximação cromática, explicando por que objetos distantes podem compartilhar rótulos no agrupamento RGB.

1.5 K-means RGB+XY (5D)

Na abordagem RGB+XY, cada pixel foi representado por cinco atributos: R, G, B e as coordenadas X, Y. As posições foram normalizadas para a escala de 0 a 255 e multiplicadas por um peso espacial, para controlar a influência da localização no cálculo das distâncias. Os demais parâmetros e os valores de K foram mantidos para permitir comparação.

```
x_normalizado = coordenadas_x / max(largura - 1, 1) * 255.0
y_normalizado = coordenadas_y / max(altura - 1, 1) * 255.0
x_ponderado = x_normalizado * peso_espacial
y_ponderado = y_normalizado * peso_espacial
dados_rgbxy = np.column_stack((
    dados_rgb, x_ponderado.reshape(-1), y_ponderado.reshape(-1)
))
```

1.6 Ajuste do peso espacial e resultados

Imagem	Peso 0,5	Peso 0,25
2apples.jpg	19 iterações; maçãs reunidas predominantemente em um cluster e fundo dividido.	57 iterações; melhor separação das regiões verde, vermelha e fundo.
2or4objects.jpg	12 iterações; fragmentações em áreas de sombra e reflexo.	11 iterações; agrupamentos cromáticos mais coerentes, com fragmentações restantes.

O peso 0,5 ampliou excessivamente a influência espacial para 2apples.jpg e prejudicou a distinção entre as maçãs. Após reduzir o peso para 0,25, a separação cromática melhorou. Esse resultado demonstra que convergência matemática não garante segmentação visual adequada, e que acrescentar coordenadas espaciais requer ponderação cuidadosa.

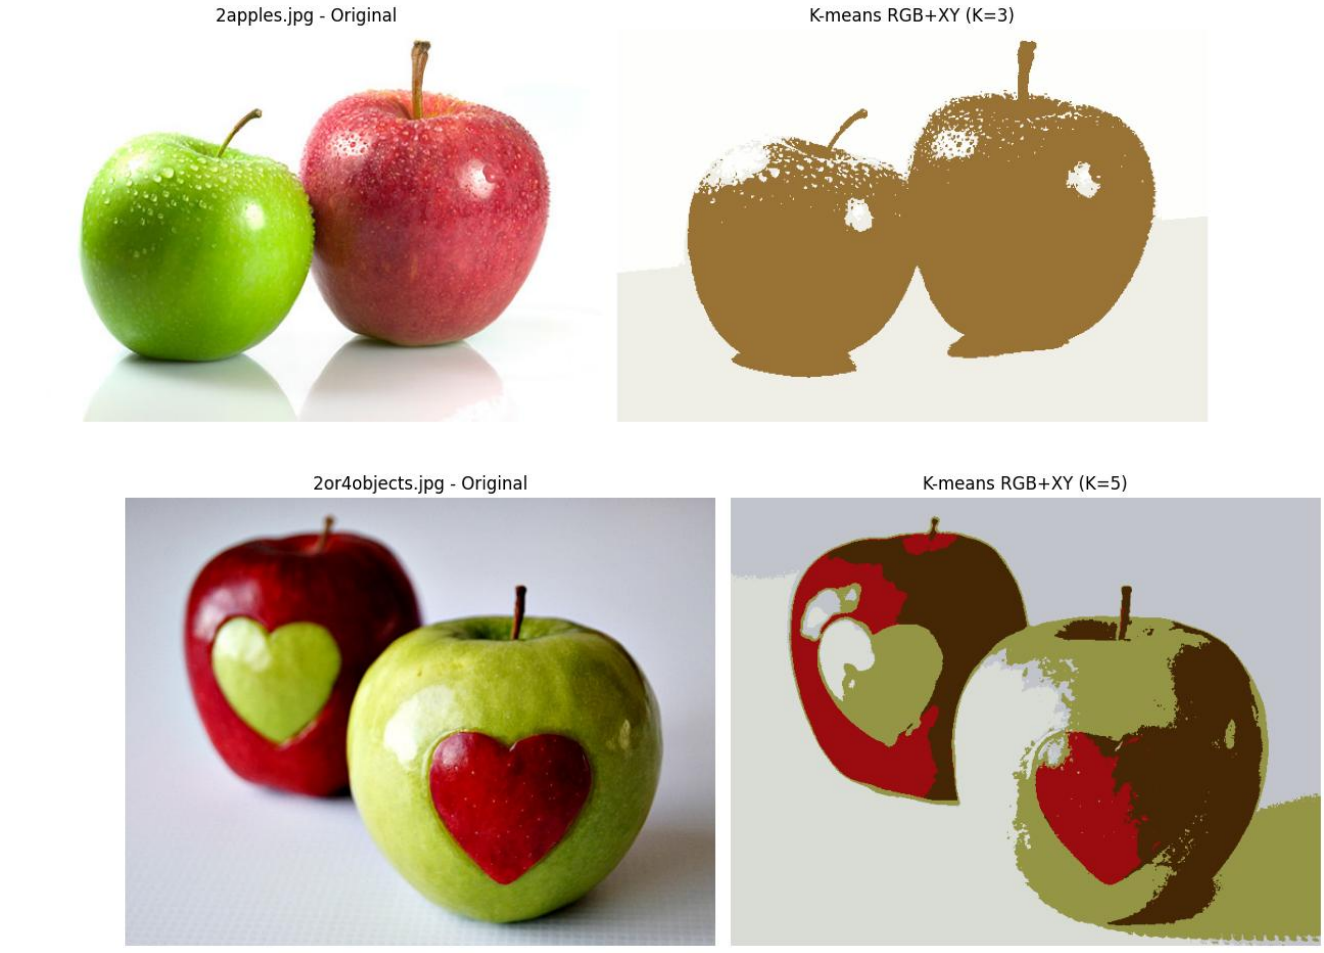


Figura 4 — comparação de RGB+XY com peso espacial 0,5 nas duas imagens. Origem: primeiro experimento RGB+XY.

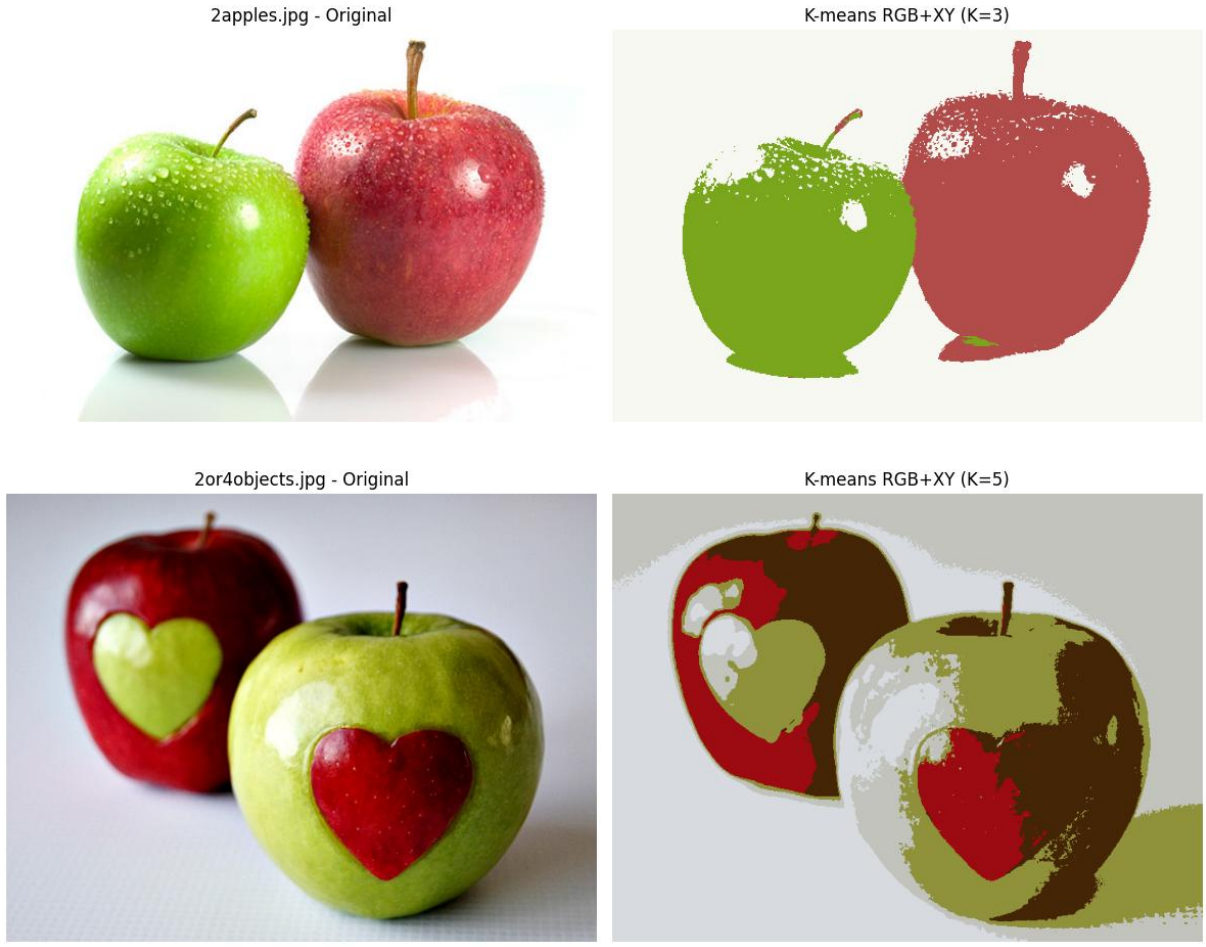


Figura 5 — comparação de RGB+XY com peso espacial 0,25 nas duas imagens. Origem: experimento ajustado RGB+XY.

1.7 Comparação RGB × RGB+XY

Na primeira imagem, RGB e RGB+XY (peso 0,25) obtiveram segmentações muito semelhantes, sem vantagem clara da posição. Na segunda, a informação espacial alterou principalmente os contornos e o fundo, mas não eliminou as fragmentações internas. A configuração de cinco atributos convergiu com menos iterações, o que não significa necessariamente menor custo computacional por iteração.

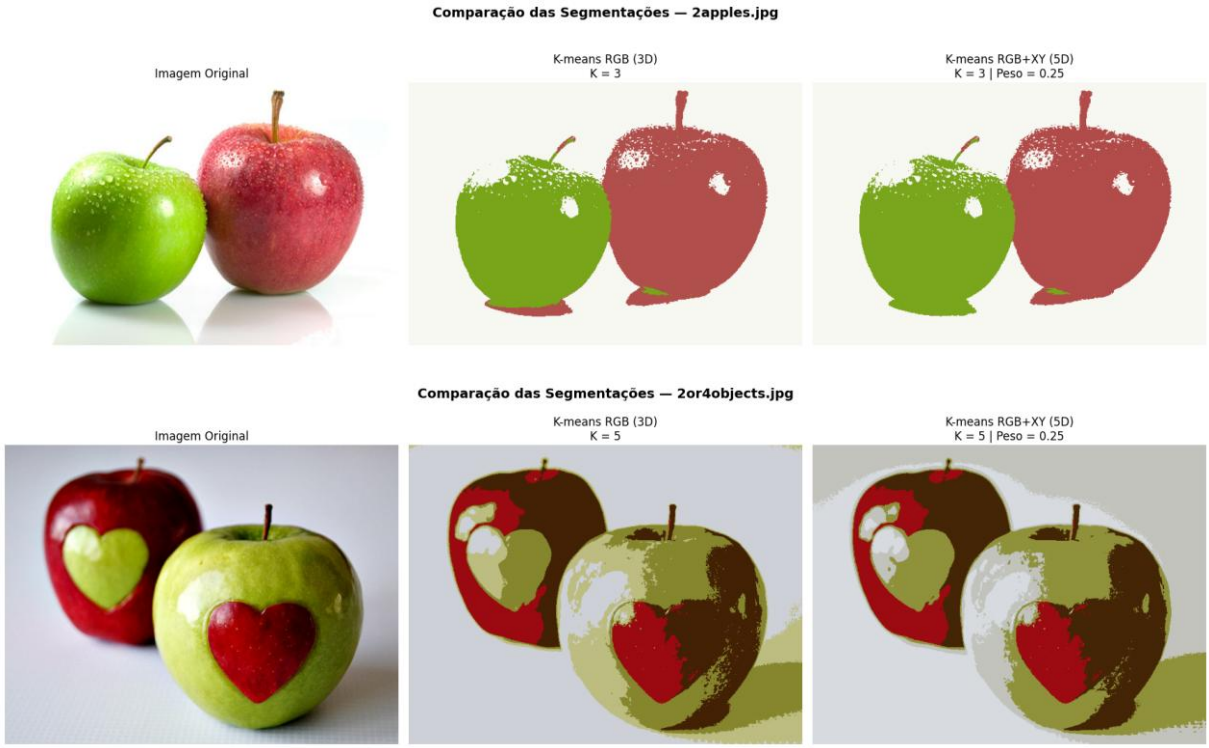


Figura 6 — imagens originais e segmentações finais RGB e RGB+XY lado a lado. Origem: comparação final do Projeto 1.

2. PROJETO 2 — SEGMENTAÇÃO DE ROSTOS

2.1 Caracterização das imagens

As quatro imagens apresentam diferentes desafios: face1.jpg contém luz natural e fundo externo; face2.jpg possui fundo claro e sombras; face3.jpeg contém cenário de tonalidades próximas às da pele; e face4.jpg apresenta pinturas faciais que alteram as cores locais. Esses contrastes permitem verificar as limitações dos critérios de limiarização e conectividade.



Figura 7 — quatro retratos originais face1.jpg, face2.jpg, face3.jpeg e face4.jpg. Origem: preparação do Projeto 2.

2.2 Limiarização de pele em RGB e HSV

A implementação foi fundamentada nos critérios apresentados por Kolkur et al. (2017). No RGB, a classificação exige simultaneamente R > 95, G > 40, B > 20, R > G, R > B e |R − G| > 15. No HSV, foram utilizados 0° ≤ H ≤ 50° e 0,23 ≤ S ≤ 0,68, sem limiar extra para brilho (V). Os valores HSV do OpenCV foram convertidos antes da aplicação desses limites.

As máscaras binárias foram construídas manualmente: pixels aceitos como pele recebem 255 (branco) e os demais, 0 (preto). O código não utilizou cv2.inRange() como função pronta de classificação.

```
condicao_pele = (
    (r > 95) & (g > 40) & (b > 20) &
    (r > g) & (r > b) & (np.abs(r - g) > 15)
)
mascara = condicao_pele.astype(np.uint8) * 255
```

2.3 Resultados da limiarização

Imagem	RGB	HSV	Análise qualitativa
face1.jpg	37,71%	49,74%	HSV incluiu mais cabelo e fundo.
face2.jpg	34,11%	45,05%	RGB apresentou maior seletividade visual.
face3.jpeg	73,60%	89,78%	Extensas áreas de cenário classificadas como pele.
face4.jpg	50,13%	52,45%	Pinturas faciais causaram falhas.



Figura 8 — comparação de máscaras RGB e HSV para face1.jpg e face2.jpg. Origem: exibir_segmentacao_pele.

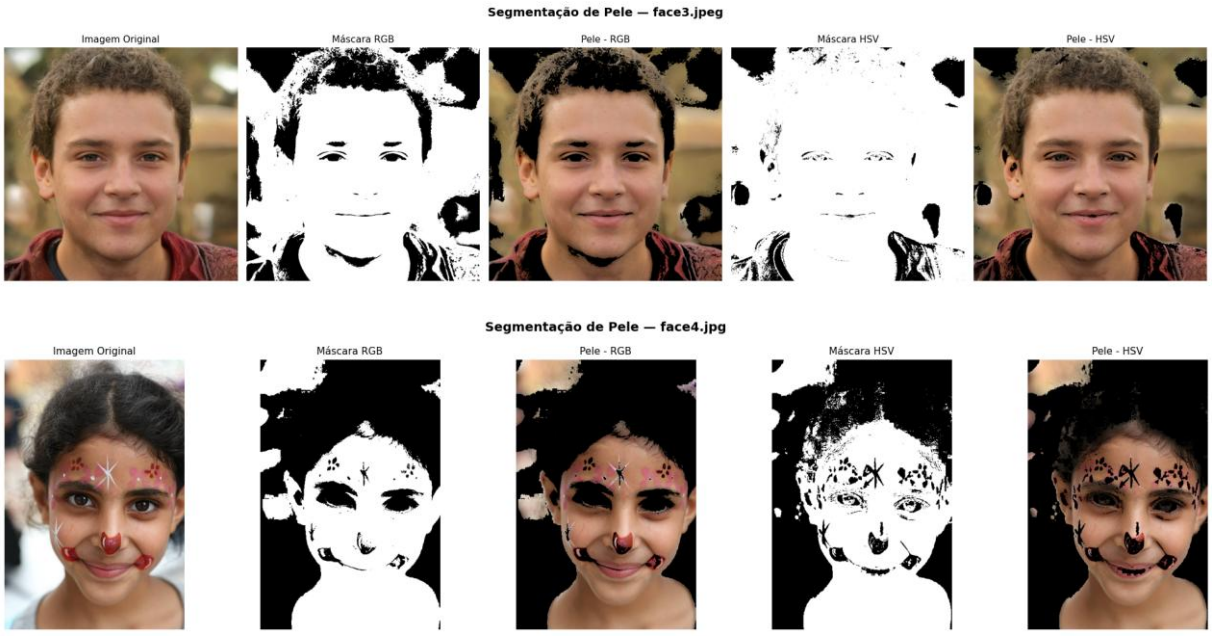


Figura 9 — comparação de máscaras RGB e HSV para face3.jpeg e face4.jpg. Origem: exibir_segmentacao_pele.

O HSV selecionou mais pixels nas quatro imagens, mas isso não corresponde automaticamente a maior qualidade. Na imagem face3.jpeg, a inclusão excessiva do fundo tornou-se especialmente evidente. O RGB foi visualmente mais seletivo em alguns casos, e não houve superioridade universal entre espaços de cor.

2.4 Segmentação semeada por crescimento de regiões

Uma semente foi escolhida manualmente em uma região de pele de cada face. O algoritmo examinou os quatro vizinhos ortogonais de cada pixel aceito e comparou os valores RGB à média atual da região. O candidato foi incorporado se a diferença absoluta em cada canal não ultrapassasse a tolerância. A região foi percorrida com uma fila (BFS), evitando recursão profunda.

```
        for canal in range(3):
            diferenca = abs(float(pixel[canal]) - media_rgb[canal])
            if diferenca > tolerancia:
                return False
        return True
```

Imagem	X (largura)	Y (altura)
face1.jpg	38%	63%
face2.jpg	39%	55%
face3.jpeg	40%	58%
face4.jpg	43%	63%

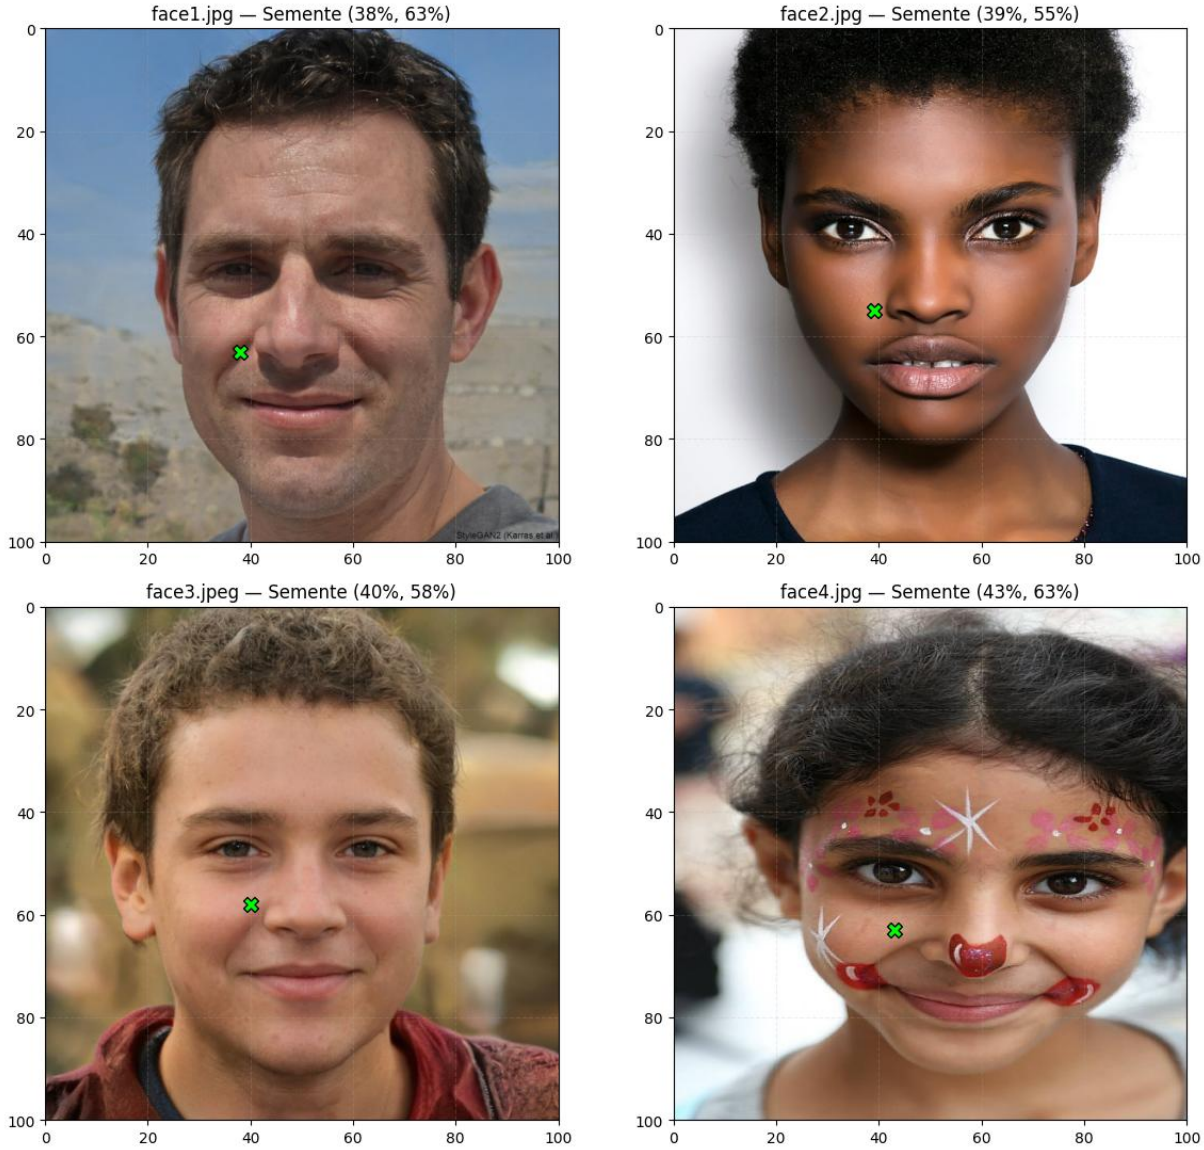


Figura 10 — quatro imagens faciais com as sementes indicadas por marcadores. Origem: visualizar_sementes.

2.5 Experimento com tolerâncias

Com tolerância inicial 30, o crescimento foi excessivamente restrito, especialmente na imagem face2.jpg, com apenas 1,24% dos pixels incorporados. Mantendo a mesma semente, testaram-se os valores 30, 45 e 60.

Tolerância	face2.jpg — área incorporada
30	1,24%
45	13,36%
60	30,57%



Figura 11 — comparação de face2.jpg com tolerâncias 30, 45 e 60. Origem: comparar_tolerancias.

2.6 Resultados finais com tolerância 60

Imagem	Pixels incorporados	Percentual	Observação
face1.jpg	625.320	59,64%	Expansão para áreas externas.
face2.jpg	174.137	30,57%	Maior abrangência de face e pescoço.
face3.jpeg	729.606	69,58%	Incluiu áreas do cenário.
face4.jpg	98.058	40,86%	Interferências de pinturas e sombras.

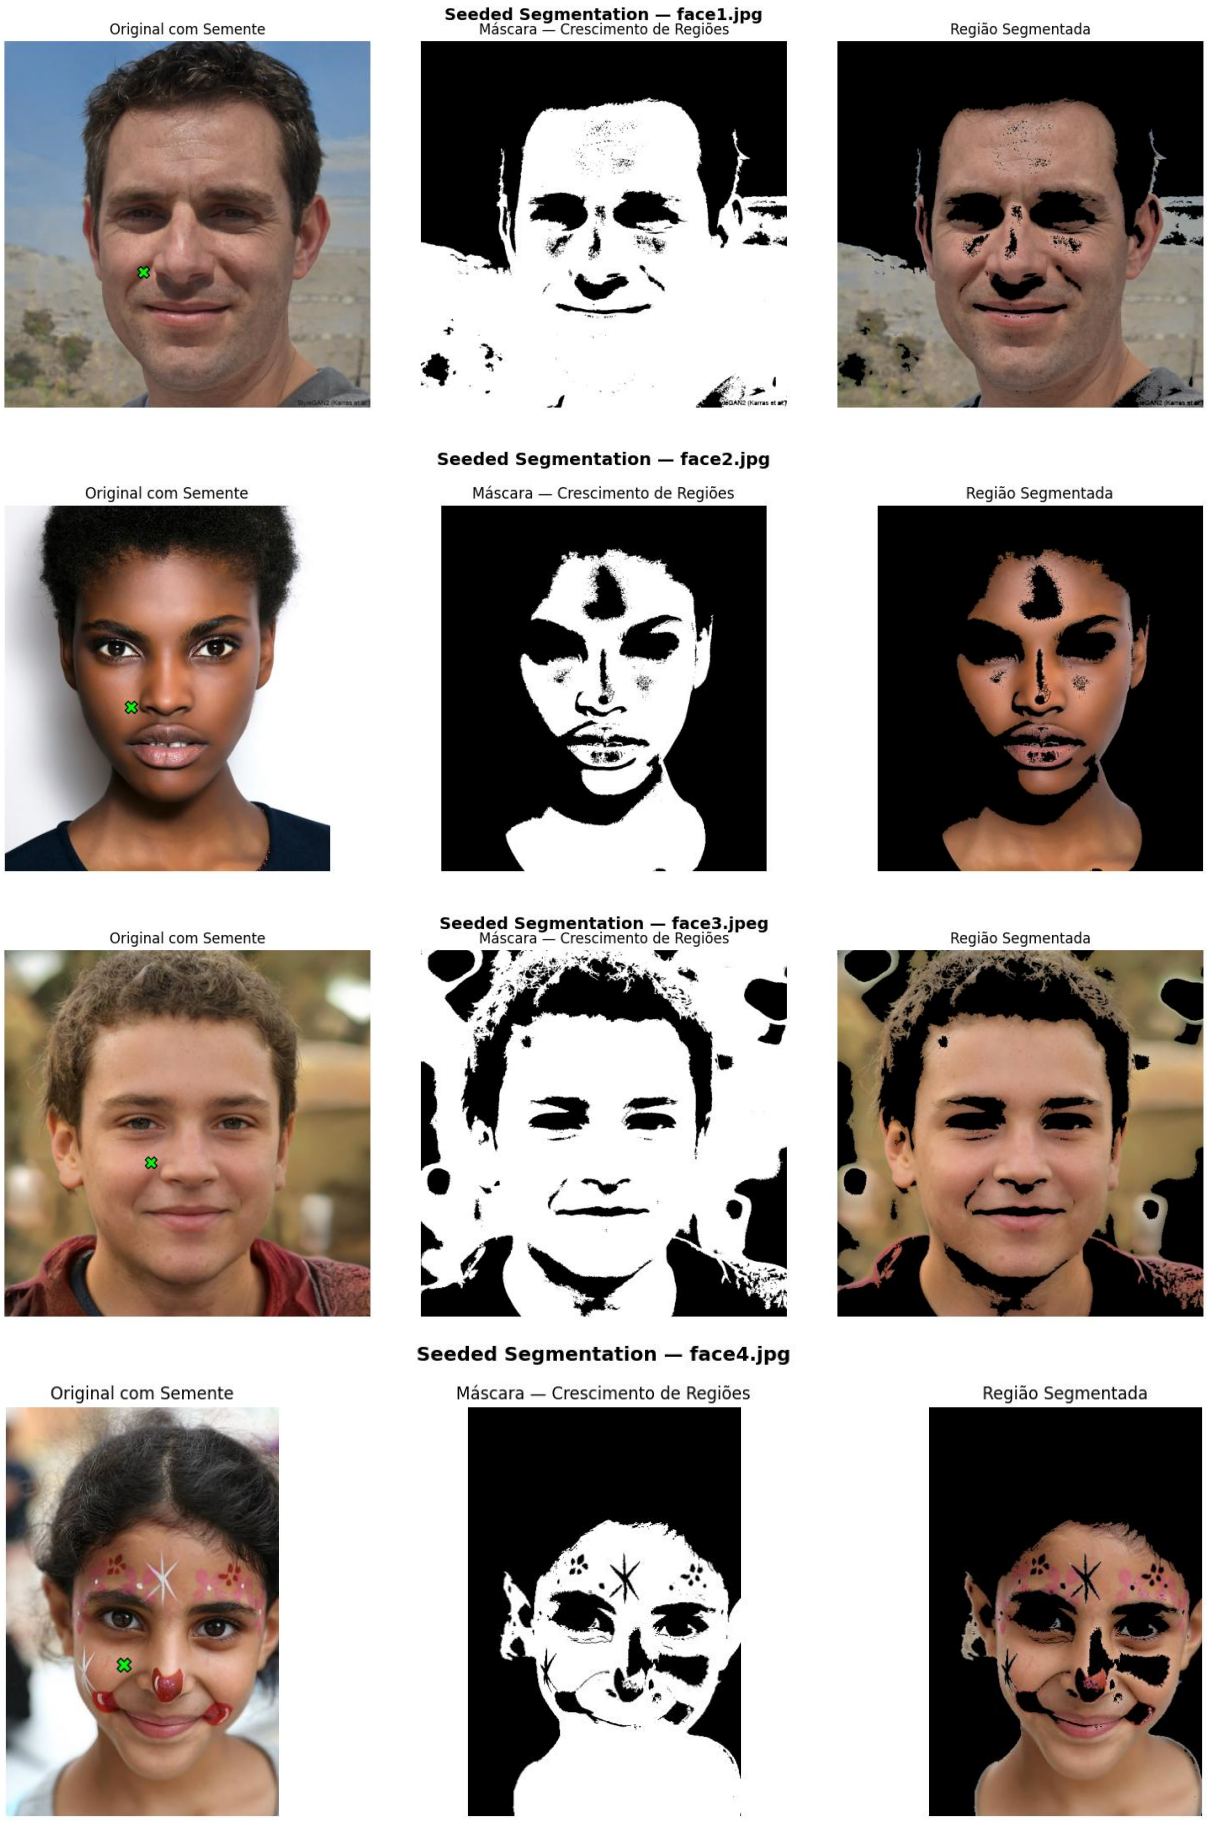


Figura 12 — quatro resultados finais: original com semente, máscara e região segmentada (tolerância 60). Origem: resultados_semeados_t60.

O crescimento a partir da semente considera a conectividade, mas pode alcançar o fundo quando há continuidade e cores suficientemente próximas. Além disso, o algoritmo avalia cada pixel candidato uma vez; pixels rejeitados não são reavaliados após mudanças da média regional.

2.7 Métricas para avaliação

Para obter medidas quantitativas de qualidade, seria necessário comparar as máscaras do algoritmo com máscaras de referência (Ground Truth). Isso permitiria calcular precisão = TP/(TP+FP), revocação = TP/(TP+FN), acurácia = (TP+TN)/(TP+TN+FP+FN), IoU = TP/(TP+FP+FN) e Dice = 2TP/(2TP+FP+FN), usando os verdadeiros positivos (TP), falsos positivos (FP), falsos negativos (FN) e verdadeiros negativos (TN).

Como não havia máscaras de referência para os quatro rostos, essas métricas não foram calculadas. Os percentuais apresentados medem apenas a área selecionada, não a acurácia do método. A avaliação foi qualitativa, com inspeção visual das máscaras e dos erros observados.

3. MORFOLOGIA MATEMÁTICA — OPÇÃO 1

3.1 Conversão e seleção dos clusters

As saídas do K-means foram convertidas em máscaras binárias: branco (255) para os agrupamentos selecionados e preto (0) para o restante. Em 2apples.jpg, foram unidos os clusters 1 e 3; em 2or4objects.jpg, os clusters 1, 3 e 4. As mesmas seleções foram utilizadas para RGB e RGB+XY com peso 0,25. Alguns tons claros das maçãs permaneceram ausentes e partes do fundo foram incluídas em 2or4objects.jpg.

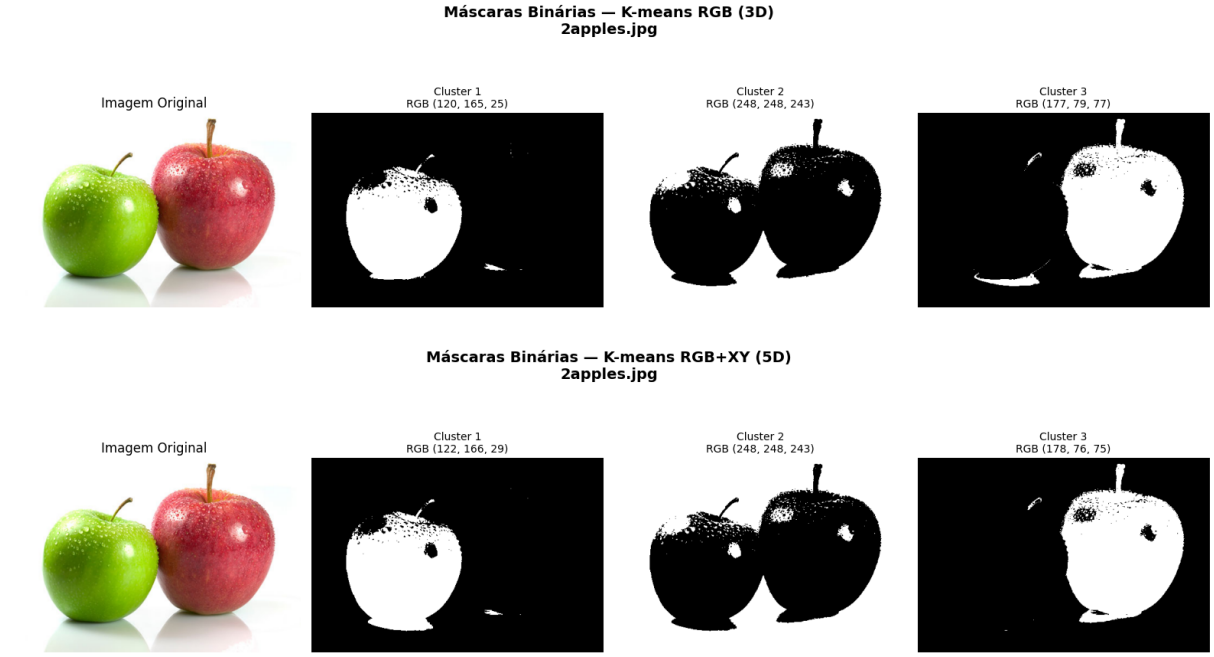


Figura 13 — máscaras individuais dos clusters de 2apples.jpg, RGB e RGB+XY. Origem: converter_clusters_em_mascaras.

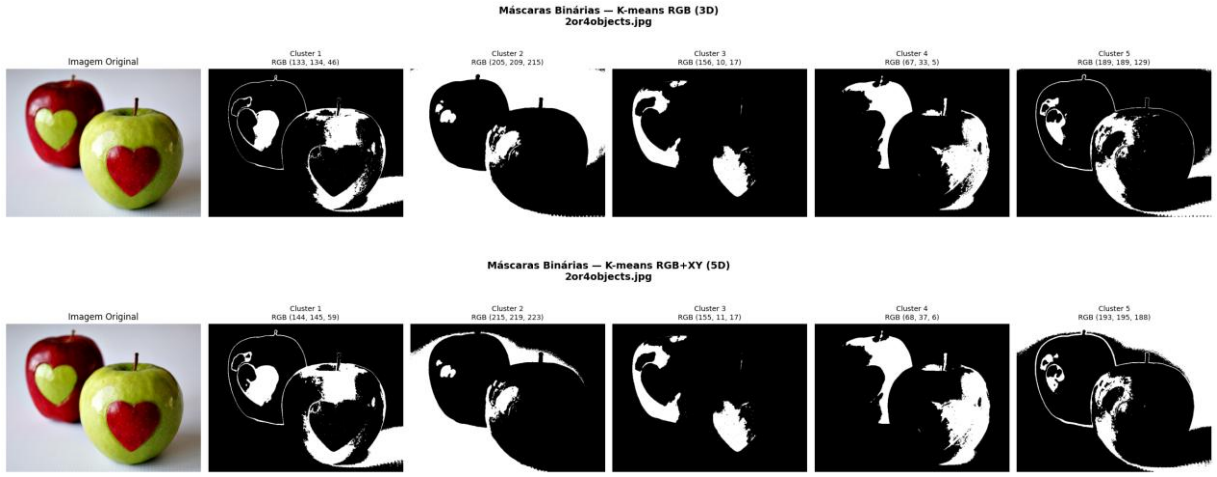


Figura 14 — máscaras individuais dos clusters de 2or4objects.jpg, RGB e RGB+XY. Origem: converter_clusters_em_mascaras.

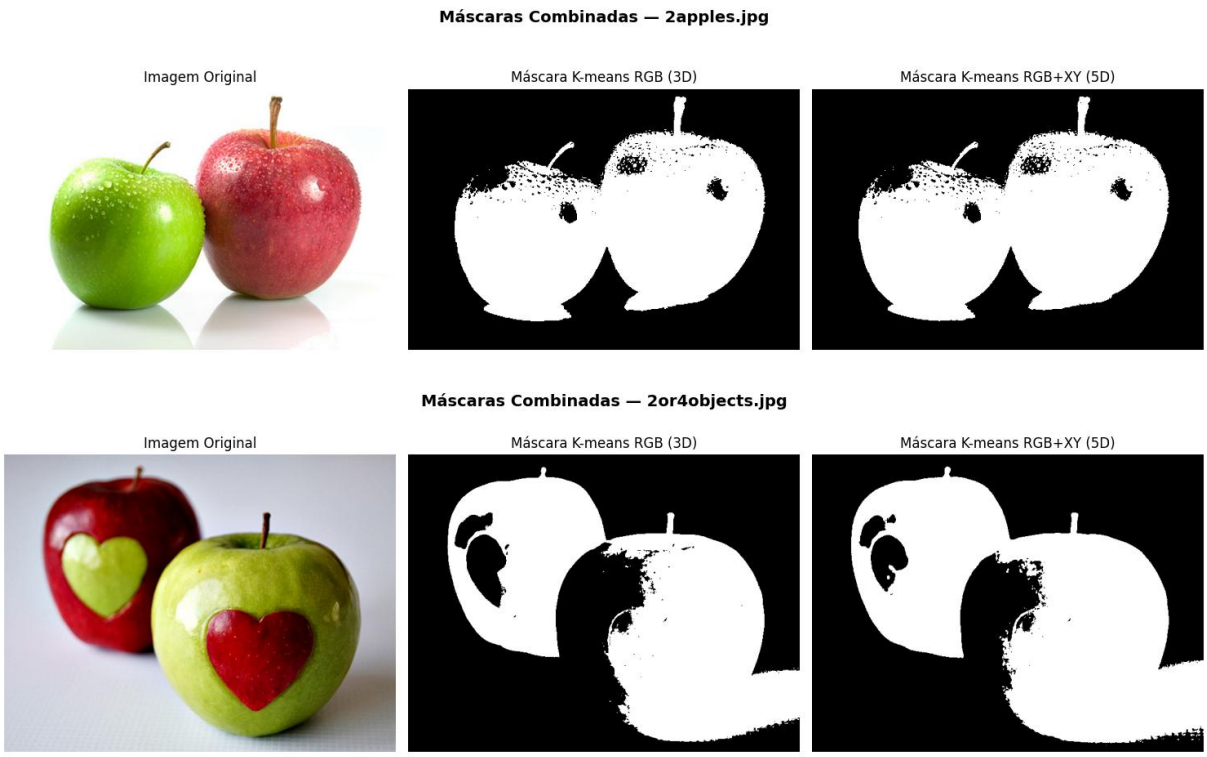


Figura 15 — máscaras combinadas das duas imagens: original, RGB e RGB+XY. Origem: combinar_clusters.

3.2 Implementação das operações morfológicas

Foram implementadas manualmente as operações de erosão, dilatação, abertura e fechamento, usando elemento estruturante quadrado de 3 × 3 pixels. A erosão mantém um pixel branco somente quando toda a vizinhança considerada é branca; a dilatação exige ao menos um branco. Abertura = erosão seguida de dilatação; fechamento = dilatação seguida de erosão.

```
mascara_erodida = erosao_binaria_manual(mascara, tamanho)
mascara_aberta = dilatacao_binaria_manual(mascara_erodida, tamanho)


mascara_dilatada = dilatacao_binaria_manual(mascara, tamanho)
mascara_fechada = erosao_binaria_manual(mascara_dilatada, tamanho)
```

3.3 Resultados da abertura e do fechamento

A abertura removeu pequenas estruturas brancas; o fechamento, aplicado após a abertura, reduziu pequenos espaços pretos. Com elemento 3 × 3, os resultados foram discretos e as falhas maiores permaneceram.

Imagem	Método	Abertura: removidos	Fechamento: adicionados
2apples.jpg	RGB	972 (1,27%)	749 (1,00%)
2apples.jpg	RGB+XY	991 (1,30%)	752 (1,00%)
2or4objects.jpg	RGB	618 (0,42%)	375 (0,26%)
2or4objects.jpg	RGB+XY	635 (0,40%)	328 (0,21%)

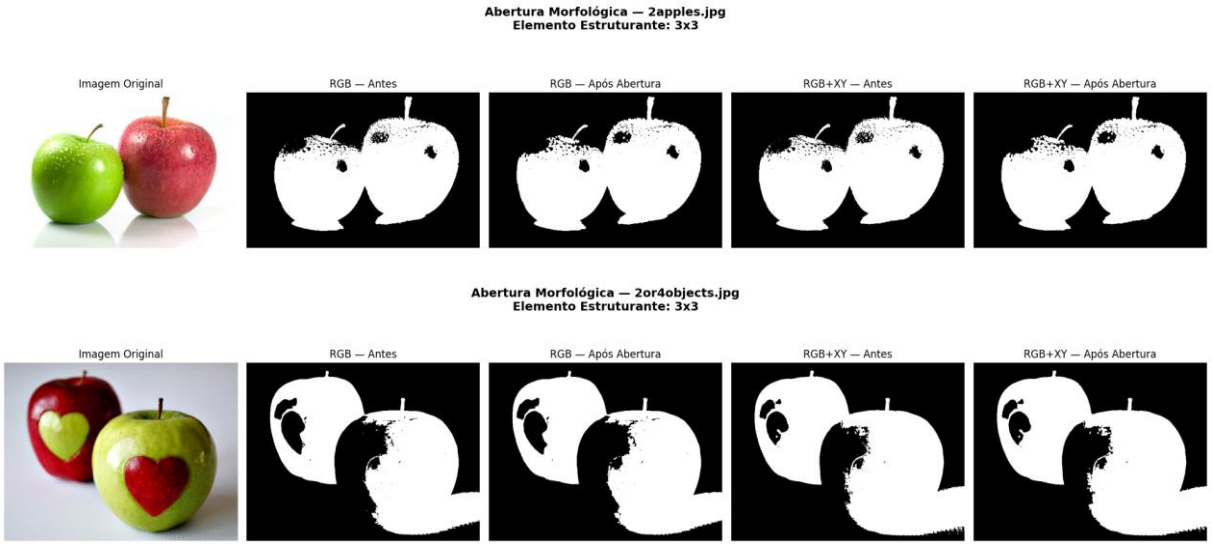


Figura 16 — comparação antes e depois da abertura (3 × 3) para as duas imagens. Origem: mascaras_abertura_rgb e mascaras_abertura_rgbxy.

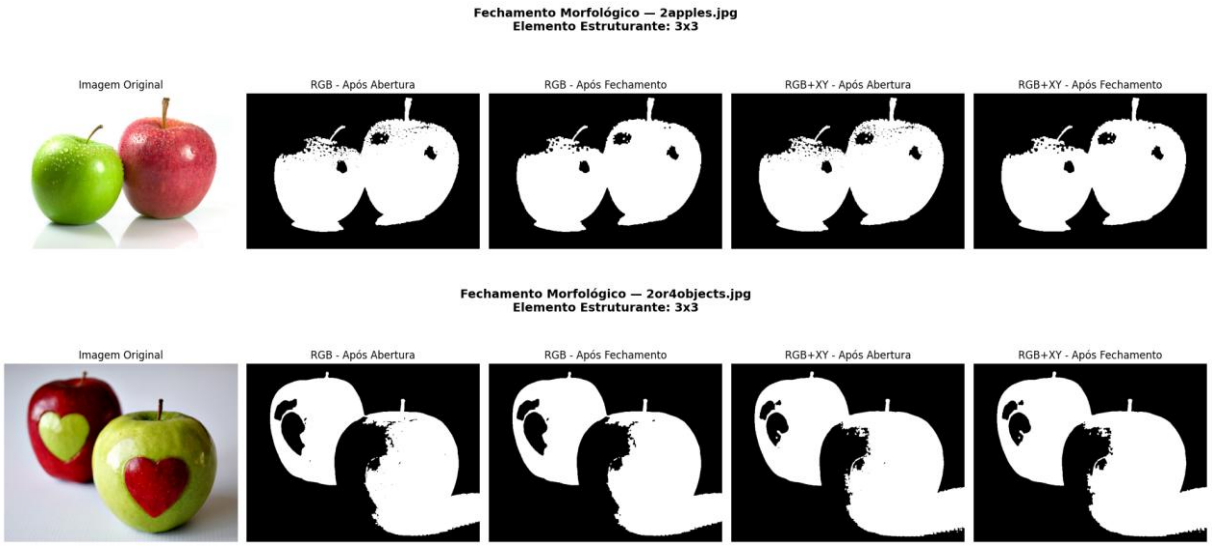


Figura 17 — comparação entre após abertura e após fechamento (3 × 3) nas duas imagens. Origem: mascaras_fechamento_rgb e mascaras_fechamento_rgbxy.

3.4 Erosão e dilatação individuais

A erosão e a dilatação também foram aplicadas separadamente sobre as máscaras originais, para isolar seus efeitos. A erosão reduziu contornos e afinou talos; a dilatação expandiu regiões e reduziu algumas falhas, mas também ampliou regiões incorretamente classificadas.

Imagem	Método	Erosão: removidos	Dilatação: adicionados
2apples.jpg	RGB	5.664 (7,43%)	4.438 (5,82%)
2apples.jpg	RGB+XY	5.680 (7,46%)	4.478 (5,88%)
2or4objects.jpg	RGB	5.656 (3,88%)	5.272 (3,62%)
2or4objects.jpg	RGB+XY	5.492 (3,44%)	5.283 (3,30%)



Figura 18 — máscaras originais, após erosão e após dilatação (ambas as imagens e métodos). Origem: resultados_operacoes_individuais.

3.5 Comparação final da morfologia

A sequência abertura → fechamento reduziu discretamente as diferenças entre as máscaras RGB e RGB+XY. A comparação considerou a quantidade de pixels em que os métodos divergiam e a IoU de sobreposição entre eles. Nesse contexto, a IoU mede concordância entre dois métodos, não a precisão em relação às maçãs reais.

Imagem	Divergências antes → depois	IoU antes → depois
2apples.jpg	274 → 262 pixels	0,9964 → 0,9966
2or4objects.jpg	14.153 → 14.089 pixels	0,9115 → 0,9117

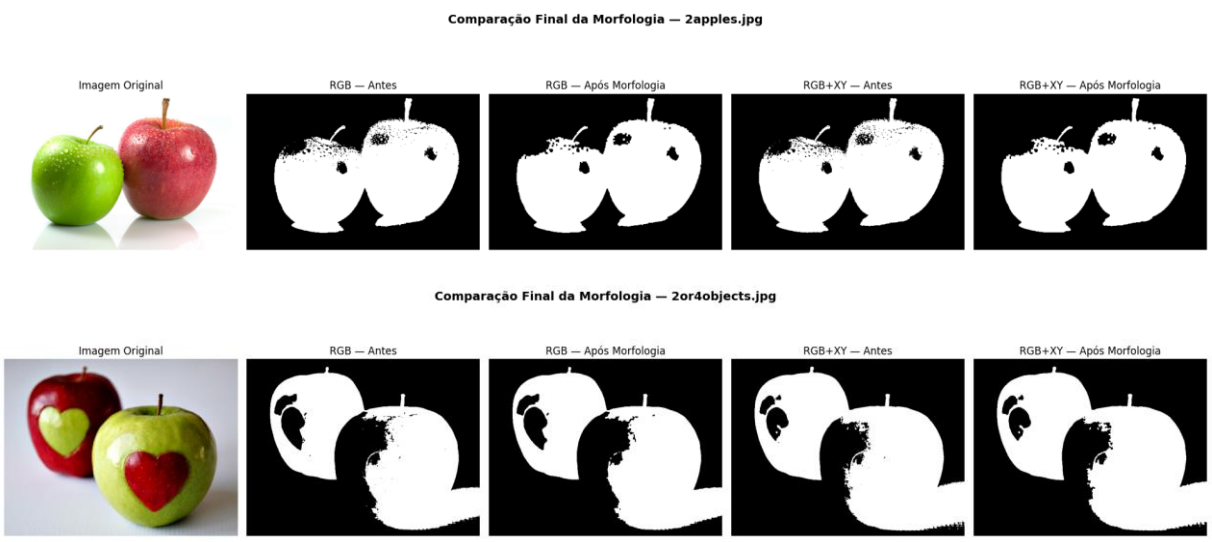


Figura 19 — comparação RGB × RGB+XY antes e após a morfologia. Origem: comparação final da morfologia.

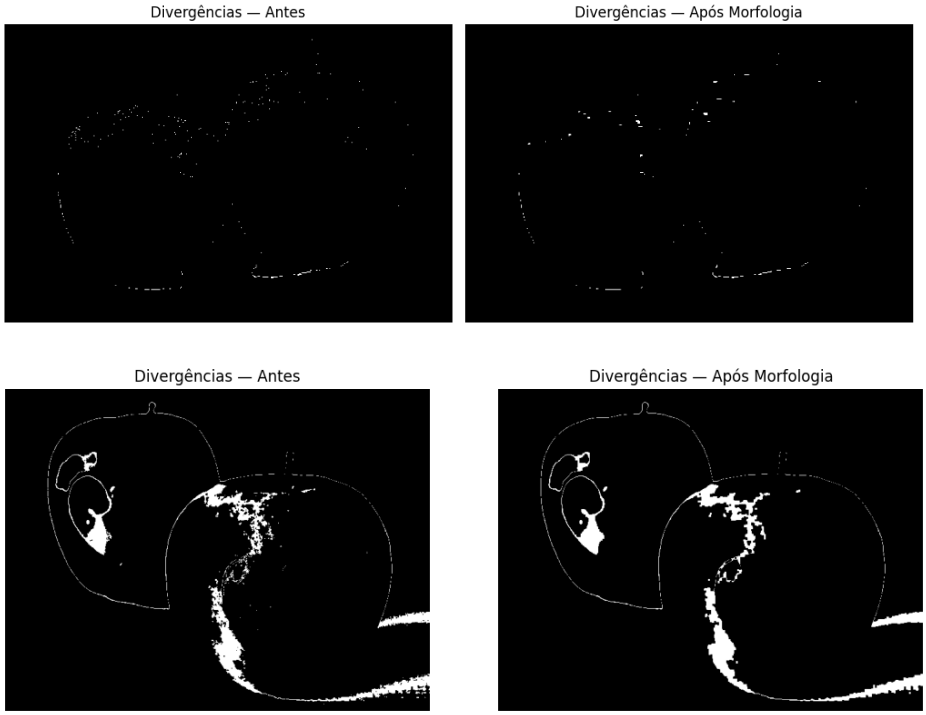


Figura 20 — mapas de divergências dos métodos antes e depois da morfologia. Origem: comparacoes_finais.

As divergências diminuíram 12 pixels na primeira imagem e 64 na segunda. Os ajustes foram úteis para ruídos e descontinuidades pequenas, mas não corrigiram os erros amplos associados à distribuição dos clusters, sombras, reflexos e fundo.

4. CONCLUSÃO GERAL

Os experimentos demonstraram que o K-means reconhece grupos de características cromáticas, mas não necessariamente objetos inteiros. A introdução de coordenadas espaciais alterou a formação dos clusters, exigindo cuidado na ponderação de sua influência. Na identificação de pele, RGB e HSV apresentaram limitações diante de fundos semelhantes, pinturas e mudanças de iluminação. O crescimento de regiões incorporou a conectividade espacial, mas mostrou forte dependência da semente e da tolerância. A morfologia refinou pequenas estruturas das máscaras, mas não substituiu a necessidade de uma segmentação inicial adequada.

Como continuidade, seria possível produzir máscaras Ground Truth e avaliar quantitativamente a qualidade da segmentação, além de testar outros parâmetros ou estratégias para reduzir falhas de classificação.

REFERÊNCIAS

KOLKUR, S. et al. Human Skin Detection Using RGB, HSV and YCbCr Color Models. 2017. Disponível em: https://arxiv.org/pdf/1708.02694.